

分子性质预测中有限验证下的候选池机会与选择稳定性： 重复嵌套审计

作者：[未提供—CONFLICT HOLD]
作者机构及完整邮寄地址：[未提供—CONFLICT HOLD]
通讯作者及电子邮箱：[未提供—CONFLICT HOLD]
ORCID：[未提供—CONFLICT HOLD]

摘要

背景：分子性质预测研究常比较不断扩大的、彼此相关的分子表征、学习器与调参变体候选库。扩张可能增加互补的化学信息，但有限验证数据未必能够稳定地排序这些机会。

方法：我们在 9 个公开端点、32 个预注册轻量候选、 $K = 4, 8, 16$ 和 32、3 个内层与 3 个外层骨架折以及 10 个划分种子下开展审计。主要分析采用 K 不变的 $K = 32$ 留一划分种子交叉拟合参考； K 依赖交叉拟合参考和同折最大值分别作为敏感性量与描述性机会量。另评估实用等价网格、PR-AUC 与训练期少数类召回约束选择、重复/弱/互补构造对照、经验相关异方差恢复模拟、候选库组成、计算暴露及化学支持。

结果：相对于 K 不变完整候选库参考，9 个端点中 8 个端点的 $K = 32$ 减 $K = 4$ 完成差距对比为负，1 个为正；7 个端点的描述性划分种子敏感性区间不含 0。 $K = 32$ 时，任务匹配中间容差下的交叉拟合成功率为 79.6%。PR-AUC 与少数类召回约束规则分别在 52.7% 和 66.0% 的分类审计单元中改变 ROC-AUC 所选候选；后者使外层少数类召回平均变化 -0.0094 ，且未稳定达到 0.80 目标。

结论：候选池扩张同时改变了可获得的机会，以及有限验证能否稳定实现这些机会。结果取决于端点、候选库组成、选择指标、候选相关性、化学支持和划分机制。 K 不变交叉拟合、实用等价报告与指标匹配选择降低了解释歧义，但不能替代外部验证，也不能证明更大候选库具有普遍效应。

科学贡献：本研究将 K 不变交叉拟合参考与 K 依赖参考和同折机会量明确分离，并量化分子基准中的实用等价与指标依赖选择。构造依赖对照和经验相关异方差模拟说明，名义候选数量不能替代有效搜索多样性。所提供的审计与报告包面向第三方复现，而非模型排行榜。

关键词：分子性质预测；候选池扩张；嵌套交叉验证；交叉拟合参考；实用等价；PR-AUC；选择稳定性；化学支持

1 引言

现代分子性质预测的候选空间已远超少量固定指纹和回归器。当前研究可能在同一基准中同时比较环形与子结构指纹、理化描述符、图模型、消息传递模型、化学语言模型、预训练表征、AutoML、集成和校准策略[1,2,5–10,16–24,34,35]。每类候选具有不同归纳偏置，最终报告性能不仅取决于单个预测器，也取决于哪些候选进入搜索、调优暴露、效用比较方式以及获胜者如何确定。因此，模型搜索本身构成研究估计对象的一部分，而不是与结论无关的预处理步骤。

候选扩张具有双重作用。真实表征机会是指新增候选捕获原登记表无法表达的互补化学信息；重复验证选择机会则来自每个候选在同一有限验证信息上贡献一个带噪效用估计。前者可能改善泛化，后者可能使特定验证骨架上偶然占优的候选获得更高排名。候选相关性会削弱但不能消除这种张力，因为高度相似的流程仍可能在有限样本下交换排序。即使外层折不参与拟合，表征、学习器、调参变体、校准规则和集成方案的反复比较仍会消耗验证信息[3,4]。

嵌套交叉验证是分离内层选择和外层评估的主要设计。内层折用于候选排序、超参数选择和所有拟合型预处理，外层折仅评估由内层程序冻结的决策，从而避免把调参分数直接当作最终性能。重复的种子化骨架划分还能在化学连贯的测试组上暴露划分敏感

性，并支持候选在共享外层折上的配对比较。对可能存在近邻分子跨随机划分的数据而言，这种设计是重要保障。

然而，嵌套评价不会自动解决候选依赖、名义 K 与有效多样性的区别、计算暴露不等、失败或不可用候选、矩阵构造敏感性以及外层最大值乐观性。外层折可以有效评价冻结选择器，但事后在多个外层候选估计中取最大值仍可能产生有限最大值偏差。当候选数超过审计单元数时，经验候选相关矩阵还会秩亏。原始、逐行中心化、固定参照和秩矩阵回答不同问题。复用公开外层折进行回顾性分解也不同于独立外部验证。

模型选择结果还必须由化学支持边限定。分子相似性和骨架新颖性会改变预测难度，活性悬崖说明结构接近并不保证性质相近[9–14,29,30,33]。罕见阳性类别还可能使 ROC-AUC 掩盖精确率、少数类召回和假阴性风险。适用域、支持分层性能、错误重叠、不确定性和条件覆盖应作为边界证据，说明总体选择结果在低相似度分子、新颖骨架、活性悬崖或稀少毒性标签处可能如何减弱，而不是作为独立确认或合并成单一得分。

因此，本研究开展回顾性锁定、任务分层的审计，而非模型排行榜。核心问题是候选池扩张创造的机会能否由有限验证信息稳定兑现。主要分析采用九个端点、32 个候选、 $K = 4, 8, 16, 32$ 和 10 个划分种子的 K 不变 $K = 32$ 留一种子参考；多表征、候选库组成、可靠性及适用的切分迁移结果保留为明确标注的五种子次要分析。所有结论均限定于已评估的端点、候选池和切分机制。

2 方法

2.1 研究设计与证据层级

本研究是对已完成分子性质实验的回顾性审计。端点、候选顺序、 K 值、种子、切分逻辑、选择规则、结局与排除规则在本次分析中保持固定。由于审计规范在原始外层结果产生后重建，本研究并非前瞻性预注册；“冻结”仅表示审计期间资格与分析规则不变，不代表未被查看的前瞻性队列（图 1）。

证据分为五层。第一层为九终点留一 seed 交叉拟合的登记前缀审计；第二层为描述性同折有限候选机会界、置换校准、组成控制和有限审计模拟；第三层为匹配规模的十二候选多表征审计；第四层为六终点扩展候选池组成干预及组件、预算、锚点、归一化、稳定性和切分机制敏感性分析；第五层为预测层可靠性与化学支持边界证据。

不同层级回答不同问题，不合并为单一排行榜。外层折仅审计冻结的内层选择决策；留一 seed 参照是主要回顾性比较，同折最大值是事后有限候选机会界，既不是可部署选择器，也不是总体真值。多表征、组成及预测面板复用公开端点定义，不构成独立外部验证。

Nested audit and evidence hierarchy

Can expanded opportunity be realised reproducibly from finite validation?




图 1. 嵌套审计与证据层级。三个内层折用于排序预注册候选，三个外层折用于审计冻结决策。轻量候选库使用 10 个种子化骨架划分；组成与可靠性等次要面板保留其原预设分析单元。K 不变 K = 32 参考、K 依赖交叉拟合参考与描述性同折机会上界明确分离，并结合实用等价集合、指标匹配选择、构造候选对照、恢复模拟、化学支持与有界下游计算。

2.2 数据集与分子标准化

主要终点包括 ESOL、FreeSolv、Lipophilicity、BBBP、BACE、ClinTox、Caco2 Wang、HIA Hou 和 P-gp Broccatelli。ESOL、FreeSolv、Lipophilicity 和 Caco2 使用 RMSE，

其余分类终点使用 ROC-AUC 作为主要选择效用。PR-AUC、Brier 分数、期望校准误差和少数类召回仅用于可靠性分析。

分子使用 RDKit 解析并按端点级固定规则标准化；保留最大有效片段，执行化学合理的电荷规范化，并保留立体信息。插补、缩放及其他拟合变换仅在相应训练折上估计。分类重复结构仅在标签一致时合并，冲突标签删除；回归重复标签取平均并记录重复数。ClinTox 清洗后含 1,376 个结构，其中 58 个为阳性。数据集摘要见表 1。

表 1. 主要数据集与终点指标。

终点	样本量	类别平衡/目标范围	指标
ESOL	1117	-11.60 至 1.58	RMSE
FreeSolv	642	-25.47 至 3.43	RMSE
Lipophilicity	4200	-1.50 至 4.50	RMSE
BBBP	1955	1494 阳性 (76.4%)	ROC-AUC
BACE	1512	690 阳性 (45.6%)	ROC-AUC
ClinTox	1376	58 阳性 (4.2%)	ROC-AUC
Caco2 Wang	904	-7.76 至 -3.51	RMSE
HIA Hou	578	500 阳性 (86.5%)	ROC-AUC
P-gp	1212	647 阳性 (53.4%)	ROC-AUC
Broccatelli			

注：分类终点以阳性例数（比例）表示类别平衡；回归终点按原始数据集的目标单位报告范围。

2.3 候选登记表与计算暴露

受控扩张登记表含 32 个共享 Morgan-512 表征的候选。K = 4、8、16 和 32 为预先固定的候选顺序前缀，依次加入正则化线性、袋装树和多类提升模型。顺序未根据外层表现重排。

候选在不同 K 下沿用相同预处理、内层折和重拟合逻辑，但候选池扩张增加总搜索暴露。当前主要十种子矩阵共 34 560 次候选拟合，覆盖种子 11、23、37、53、71、83、97、113、127 和 149，记录候选拟合时间 8 130.16 秒。历史五种子拟合数与时间仅保留于补充数据溯源表，不计入当前主要分析。匹配多表征、切分迁移和候选库组成干预均在表 2 中明确标注为次要分析；完整资源见补充表。

表 2. 审计组成与记录的计算暴露。

审计组成	候选池	评价设计	记录的计算暴露
受控前缀主要审计	32 个 Morgan 候选	9 端点；K = 4、8、 16、32；10 种子；3 外层×3 内层折	34 560 次候选拟合；候 选拟合时间 8 130.16 s

审计组成	候选池	评价设计	记录的计算暴露
校准与重采样控制	已存储的	5 000 次置换；每模式	无新增模型拟合
匹配多表征审计	32 候选结果	/K/种子 100 次重采样	
(次要)	12 个多表	9 端点；5 种子；全部	6 480 次候选拟合
切分机制迁移审计	征候选	C(12,3)登记子集	
(次要)	32 个	3 端点；种子化骨架与	5 760 次候选拟合
候选库组成干预	Morgan 候选	Tanimoto 分量切分	
(次要)	三类锁定	6 端点；K = 4、8、	1 080 个外层单元；下游
	候选池	16、32；组成与稳定性控制	拟合/预测时间 64 616.35 s

2.4 重复嵌套骨架评估

主要分析的划分种子为 11、23、37、53、71、83、97、113、127 和 149。分类采用种子化分层骨架组折，回归采用种子化骨架组平衡折；每个种子含 3 个外层骨架折，并在每个外层训练分区内生成 3 个内层骨架折。Bemis–Murcko 骨架组保持完整，分配使用种子相关的随机并列处理并尽量平衡样本数，且不依据模型性能选择划分。仅使用前五个种子的分析均明确标注为五种子次要分析。

验证最优选择器按平均内层效用排序候选，分类效用为 ROC-AUC，回归效用为负 RMSE；并列时按登记顺序决定。候选在完整外层训练分区重拟合后仅在外层折评估一次。完整划分清单记录样本数、骨架数、标签均值/标准差/范围、split hash 及无跨折骨架重叠检查。

2.5 审计差距与排序估计量

正式数学定义集中列于第 2.15 节；本节仅说明各估计量的科学解释、方向和汇总层级。候选选择、观测有限审计最佳、原始选择损失及机会校正排序的正式定义见公式 (1) – (5)。原始选择损失表示验证所选候选不同于观测有限审计最佳时损失的有限审计效用；分类任务中为 ROC-AUC 差，回归任务中为 RMSE 增加，因为回归效用定义为负 RMSE。范围归一化损失仅作为敏感性估计量，而非普适化学效应。

CAHit@3 用于判断观测有限审计最佳在校正随机排序恢复概率后是否进入验证前三名；标准化 MRR 用于衡量其完整验证名次相对于随机排序期望的位置。NDCG、Spearman 相关、Kendall 相关及验证秩百分位作为互补排序摘要保留。置换与分级信号注入对照仅校准指标零点和信号恢复，不改变经验候选选择。

主要轻量候选库估计量先在每个划分种子内平均 3 个外层折，再在每个终点内以 10 个种子为区组汇总。五种子次要面板保留原分析单元并明确标注。跨终点描述性汇总使用终点层中位数、四分位距和范围；分类与回归不合并，因为 ROC-AUC 差与 RMSE 增加不是可交换单位。

2.6 有效多样性估计

十种子主要有效多样性审计对每个端点和 K 构建 $30 \times K$ 外层效用矩阵和 $90 \times K$ 内层效用矩阵，来源为 10 个划分种子、每种子 3 个外层折以及每个外层训练分区 3 个内层折。预设分析原始效用、逐行中心化效用、固定参照相对效用和单元内秩四种变换。图 2 与表 S6 展示十种子外层矩阵；表 S6 同时报告相应内层矩阵。五种子候选库组成与多表征矩阵仍作为独立次要分析，不与上述估计合并。

有效多样性由候选效用矩阵而非候选标签或模型家族数量计算。报告经验相关谱、Ledoit–Wolf 收缩相关谱、谱熵有效秩、参与率有效秩、非对角相关中位数及收缩系数。数值方差不超过 10^{-12} 的候选列在相关估计前剔除并记录变换后列数；固定参照相对矩阵以候选 1 为参照，因此含 $K - 1$ 列。敏感性分析逐一删除 10 个种子、外层折标签以及内层矩阵的内层折标签，并用 3 个额外的候选库预设参照重复计算；参照不依据外层表现选择。跨端点汇总采用中位数、IQR 和范围，不把 9 个端点视为总体随机样本，也不报告总体推断性置信区间（表 S6–S7）。

2.7 候选组成控制

随机顺序、随机子集和家族平衡控制用于判断 K 趋势是否由特定前缀组成驱动。每种模式在终点内汇总，随机化 seed 仅为重采样装置，不作为独立终点。 $K = 32$ 时各模式均等于完整候选池。

2.8 留一种子参考与完成差距分解

令外层审计单元 $u = (s, f)$ ，并定义 $N_{-s} = |U_{-s}|$ 。公式 (6) – (13) 正式定义验证所选候选 $\hat{j}_u(K)$ 、K 不变完整候选库参考 $j_{\text{ref}}^{\text{inv}}(-s)$ 、K 依赖资格前缀参考 $j_{\text{ref}}^{\text{dep}}(-s, K)$ 、K 不变完成差距 $G_{\text{inv}}(u, K)$ 、K 依赖前缀内选择差距 $G_{\text{dep}}(u, K)$ 、同折有限集合机会差距 $G_{\text{same}}(u, K)$ 和可用性分量 $G_{\text{avail}}(u, K)$ 。恒等式 $G_{\text{inv}}(u, K) = G_{\text{avail}}(u, K) + G_{\text{dep}}(u, K)$ 将候选可用性与前缀内选择分开。先以每个种子的 3 个外层折定义 $\bar{G}_{\text{inv}, e, s}(K)$ ，再由端点层 $\Delta_{\text{inv}}(e)$ 以 10 个种子为区组求配对平均；负值表示 $K = 32$ 下相对于完整候选库参考的完成差距更小，正值表示 $K = 4$ 下更小。

参考身份在不使用留出种子的数据上选择，并以预注册候选顺序解决并列；同折最大值仅为描述性机会界。该设计降低同单元循环性，但仍复用相同公开端点、候选登记表和划分生成器，不构成独立外部验证。十个种子区组是敏感性重复，而不是十项独立研究。

2.9 有限审计赢家乐观偏差模拟

在所有候选真实标准化效用相同的情形下，模拟相关高斯审计误差。K 取 4、8、16、32，有效审计量取 25、50、100、200，候选相关取 0、0.5、0.9，每个配置 30,000 次重复。赢家乐观偏差定义为最大观测效用减相应候选真实效用。该模拟仅说明有限最大值的机械性质，不用于校正真实终点。

2.10 等规模多视图压力测试

12 候选登记表由 Morgan-512、MACCS、RDKit2D 及其拼接表征与 3 类学习器交叉组成。利用候选级内外层效用，完整枚举 $C(12, 3) = 220$ 个 $K=3$ 子集，无需重新训练。全部子集属于同一登记表的组成敏感性分析，并非 220 次独立实验。

子集采用互斥组成分类：Morgan-only 参照、仅单一表征、仅单一学习器、无拼接的表征平衡、含拼接的表征平衡及混合不平衡。每个终点报告中位数、IQR、分布范围和优于 Morgan-only 的子集比例，不计算把 220 个重叠子集当作独立样本的 P 值。

2.11 有限表征基线分析

六终点四模型面板包括 RDKit-RF、GCN、ChemBERTa 冻结嵌入线性探针和 MoLFormer 冻结嵌入线性探针。各模型训练预算并不等同，因此该面板仅用于共享切分下的选择行为与误差结构。该预测层面板未包含 D-MPNN；另行锁定的一轮 D-MPNN 候选仅用于扩展候选池组成干预。由于缺少完整共享切分审计，TabPFN 未纳入。

2.12 可靠性与化学边界分析

逐样本预测按最大训练集 Morgan Tanimoto 划分为低支持(<0.5)、中支持(0.5 至 <0.7)和高支持(≥ 0.7)。每个区间比较所选模型和交叉拟合参照性能、错误 Jaccard 重叠、模型分歧、不确定性—错误相关和假阴性富集。

外层精确 Murcko 骨架按设计均未见，因此采用预先固定的骨架指纹最大相似度 0.5 阈值区分‘已见或相关骨架’与‘新颖骨架’。四模型面板还计算预测矩阵和误差矩阵的相关性、谱熵有效秩和参与率有效秩，不外推至 32 候选登记表。

2.13 切分机制迁移审计

选择 ClinTox、BACE 和 ESOL 分别代表罕见类别分类、常规分类和回归。保持锁定的 32 候选 Morgan-512 登记表、候选顺序、 $K = 4/8/16/32$ 前缀、种子 11/23/37/53/71 以及 3 外层 $\times$ 3 内层设计不变。结构分离重跑将 Tanimoto ≥ 0.70 的分子对连边，并将每个连通分量作为内外层均不可拆分的组。阈值与分配规则在正式模型拟合前经切分可行性检查后固定，模型性能不参与分组。

种子化贪心分配同时平衡样本量以及分类任务的两类样本量。所有正式切分均要求组间无重叠、跨折最大 Tanimoto 低于 0.70 且分类折保留两类，禁止随机回退。迁移审计

新增 5,760 次候选拟合，并比较 CAHit@3 的 $K = 32$ 减 $K = 4$ 变化、留一种子交叉拟合差距和四种矩阵变换下的 Ledoit–Wolf 有效秩。

2.14 扩展的等规模候选池组成干预

端点与候选池设计

在读取扩展结果前按任务覆盖固定六个端点：分类为 ClinTox、BACE、BBBP，回归为 ESOL、Lipophilicity、Caco2 Wang。同质 Morgan、多表征经典和现代增强三类精确前缀候选池均在 $K = 4, 8, 16, 32$ 下，采用种子 11、23、37、53、71 以及一致的 3 外层×3 内层折评价。共享 Morgan 线性候选固定在首位，候选配置与顺序不随前缀改变。

组件消融

固定 K 消融在 $K = 16$ 和 32 下比较多表征经典、经典+ChemBERTa、经典+MoLFormer、经典+D-MPNN 及完整现代增强候选池。每次加入现代组件均替换一个预设经典候选，保持 K 严格相同。另行锁定的一轮 D-MPNN 仅属于本扩展干预。

等下游预算分析

各锁定前缀按端点与 K 使用多表征经典候选池的中位下游时间阈值截断，外层性能从不参与保留决策。记录时间仅包含内外层下游拟合与预测，不含模型获取、编码器预训练或缓存嵌入提取，因此该分析是受限下游计算敏感性而非端到端效率比较。

锚点、归一化、选择稳定性与切分机制敏感性

锚点包括共享 Morgan 线性候选、固定 Morgan 随机森林和预设候选池中位候选；报告原始增益、端点 MAD 归一化及配对同质审计最优归一化。候选、表征和学习器家族频率、标准化选择熵、众数比例、留一种子一致性及相邻折切换用于刻画稳定性。ClinTox、BACE 和 ESOL 在种子化骨架划分与 Tanimoto 分量切分下完成三候选池闭环，候选池、种子、折、规则和指标均保持固定。

2.15 数学估计量与矩阵相对多样性

令 $u = (s, f)$ 表示由划分种子 s 与外层折 f 构成的外层审计单元； $V(u, j)$ 为候选 j 的平均内层验证效用， $A(u, j)$ 为其外层审计效用。主要分析 $S_{\text{main}} = 10$ 且 $F = 3$ ；明确标注的次要分析 $S_{\text{secondary}} = 5$ 。符合资格的前缀 C_K 、候选顺序与并列规则均在计算报告对比前固定。

表 3. 审计估计量使用的数学符号。

符号	定义
S_{main}	主要分析的划分种子数（10）
$S_{\text{secondary}}$	明确标注的次要分析所用种子数（5）
s	划分种子
F	每个种子的外层折数（3）
f	外层折
$u = (s, f)$	外层审计单元
U_{-s}	除留出种子 s 以外的外层审计单元集合
N_{-s}	U_{-s} 中的审计单元数； $N_{-s} = U_{-s} $
j	候选
K	候选数量
C_K	规模 K 下符合资格的预注册候选前缀
$V(u, j)$	内层验证效用
$A(u, j)$	外层审计效用（回归使用负 RMSE 方向）
τ	实用等价报告容差

表 3（续）. 审计估计量使用的数学符号。

符号	定义
ε_{num}	数值稳定常数，固定为 10^{-12}
$\hat{j}_u(K)$	规模 K 下由内层验证选择的候选
$j_{\text{ref}}^{\text{inv}}(-s)$	不使用种子 s 选出的 K 不变完整候选库参考
$j_{\text{ref}}^{\text{dep}}(-s, K)$	不使用种子 s 、在合格前缀内选出的 K 依赖参考
$G_{\text{inv}}(u, K)$	K 不变完整候选库完成差距
$G_{\text{dep}}(u, K)$	K 依赖合格前缀选择差距
$G_{\text{same}}(u, K)$	同折有限集合机会差距
$G_{\text{avail}}(u, K)$	可用性分量； $G_{\text{inv}} = G_{\text{avail}} + G_{\text{dep}}$
$\bar{G}_{\text{inv},e,s}(K)$	每个种子内 3 个外层折的 G_{inv} 均值
$\Delta_{\text{inv}}(e)$	以种子为区组的端点层 $K=32$ 减 $K=4$ 对比
$\mathbf{S}_{\text{cov}}$	Ledoit-Wolf 收缩中的样本协方差矩阵
λ_i	收缩相关矩阵的非负特征值
p_i	和为 1 的特征值比例
π_j	候选 j 的选择比例

选择与排序估计量

其中， r_u 为外层有限审计最佳候选在内层验证排序中的名次， q 为排序截断值（ $q = 3$ ）， I 为示性函数， H_K 为第 K 个调和数。

公式（1）–（5）定义候选选择、有限审计选择损失和机会校正排序；公式（6）–（13）定义验证所选候选、 K 不变与 K 依赖参考、四类差距、可用性分解及端点层 Δ_{inv} 对比；公式（14）–（17）定义矩阵变换和有效秩；公式（18）–（21）定义候选库组成对比、归一化增益和选择熵。

$$\hat{j}_u(K) = \arg \max_{j \in \mathcal{C}_K} V(u, j) \quad (1)$$

$$j_{\text{best},u}(K) = \arg \max_{j \in \mathcal{C}_K} A(u, j) \quad (2)$$

$$L_u(K) = A(u, j_{\text{best},u}(K)) - A(u, \hat{j}_u(K)); \tilde{L}_u(K) = \frac{L_u(K)}{\max_{j \in \mathcal{C}_K} A(u, j) - \min_{j \in \mathcal{C}_K} A(u, j) + \varepsilon_{\text{num}}} \quad (3)$$

$$CAHit_{q,u} = \frac{I(r_u \leq q) - \frac{q}{K}}{1 - \frac{q}{K}}, q = 3 ; \quad MRR_u = \frac{1}{r_u} \quad (4)$$

$$E_{0(MRR)} = \frac{H_K}{K} ; \quad MR\tilde{R}_u = \frac{MRR_u - \frac{H_K}{K}}{1 - \frac{H_K}{K}} \quad (5)$$

完成差距估计量与分解

记 U_{-s} 为除留出种子 s 以外的全部外层审计单元，并定义 $N_{-s} = |U_{-s}|$ 。参考训练集包含除留出种子 s 以外的全部外层单元。主要参考使用 $S_{\text{main}} = 10$ 中的其余 9 个种子；五种子次要分析只在其自身范围内使用其余 4 个种子。公式 (6) – (13) 完整定义参考候选、 G_{inv} 、 G_{dep} 、 G_{same} 、 G_{avail} 、分解关系和 $\Delta_{\text{inv}}(e)$ 。负 $\Delta_{\text{inv}}(e)$ 表示 $K = 32$ 下相对于完整候选库参考的完成差距更小；正值表示 $K = 4$ 下更小。

$$\hat{j}_u(K) \equiv j_u^K = \arg \max_{j \in \mathcal{C}_K} V(u, j) \quad (6)$$

$$j_{\text{ref}}^{\text{inv}}(-s) = \arg \max_{j \in \mathcal{C}_{32}} \frac{1}{N_{-s}} \sum_{u \in U_{-s}} A(u, j) \quad (7)$$

$$j_{\text{ref}}^{\text{dep}}(-s, K) = \arg \max_{j \in \mathcal{C}_K} \frac{1}{N_{-s}} \sum_{u \in U_{-s}} A(u, j) \quad (8)$$

$$G_{\text{inv}}(u, K) = A(u, j_{\text{ref}}^{\text{inv}}(-s)) - A(u, \hat{j}_u(K)) \quad (9)$$

$$G_{\text{dep}}(u, K) = A(u, j_{\text{ref}}^{\text{dep}}(-s, K)) - A(u, \hat{j}_u(K)) \quad (10)$$

$$G_{\text{same}}(u, K) = \max_{j \in \mathcal{C}_K} A(u, j) - A(u, \hat{j}_u(K)) \quad (11)$$

$$G_{\text{avail}}(u, K) = A(u, j_{\text{ref}}^{\text{inv}}(-s)) - A(u, j_{\text{ref}}^{\text{dep}}(-s, K)) \quad (12)$$

$$G_{\text{inv}}(u, K) = G_{\text{avail}}(u, K) + G_{\text{dep}}(u, K)$$

$$\bar{G}_{\text{inv},e,s}(K) = \frac{1}{F} \sum_{f=1}^F G_{\text{inv},e}((s, f), K) \quad (13)$$

$$\Delta_{\text{inv}}(e) = \frac{1}{S_{\text{main}}} \sum_{s=1}^{S_{\text{main}}} [\bar{G}_{\text{inv},e,s}(32) - \bar{G}_{\text{inv},e,s}(4)] \quad (14)$$

矩阵变换与有效秩

X 为外层效用矩阵；Ledoit–Wolf 表达式中的 Scov 表示样本协方差，不得与 $S_{\text{main}} = 10$ 或 $S_{\text{secondary}} = 5$ 混淆。 T 为缩放单位阵目标， λ_i 为收缩相关矩阵的非负特征值， p_i 为其和为 1 的比例。公式 (14) – (17) 定义矩阵变换与有效秩。

$$\mathbf{X}_{\text{raw},u,j} = A_{u,j} ; \quad \mathbf{X}_{\text{ctr},u,j} = A_{u,j} - \left(\frac{1}{K}\right) \sum_l A_{u,l} \quad (15)$$

$$\mathbf{X}_{\text{ref},u,j} = A_{u,j} - A_{u,j_0} ; \quad \mathbf{X}_{\text{rank},u,j} = \text{rank}_{j(A_{u,j})} \quad (16)$$

$$\hat{\Sigma}_{LW} = (1 - \alpha)S_{cov} + \alpha T \quad ; \quad p_i = \frac{\lambda_i}{\sum_l \lambda_l} \quad (16)$$

$$r_{ent} = \exp[-\sum_i p_i \ln(p_i)] \quad ; \quad r_{PR} = \frac{(\sum_i \lambda_i)^2}{\sum_i \lambda_i^2} = \frac{1}{\sum_i p_i^2} \quad (17)$$

候选池组成与归一化

hom 表示同质 Morgan 候选池；完整下游效率与 Pareto 定义见补充方法。公式 (18)

– (21) 定义组成对比、归一化增益和标准化选择熵。

$$\begin{aligned} G_{best,u,p,K} &= \max_{j \in \mathcal{C}_{p,K}} A_{u,j} - A_{u,a} \\ G_{sel,u,p,K} &= A_{u,\hat{j}_{u,p,K}} - A_{u,a} \end{aligned} \quad (18)$$

$$\begin{aligned} \tilde{G}_{sel,e,p,K} &= \frac{1}{SF} \sum_{s,f} \frac{G_{sel(s,f),p,K}}{G_{best(s,f),hom,K}} \\ d_{rel,e,p,K} &= \frac{r_{ent}(\mathbf{x}_{e,p,K})}{K} \end{aligned} \quad (19)$$

$$\tilde{L}_{CF,e,p,K} = \frac{1}{SF} \sum_{s,f} \frac{[A(s,f)j_{ref-s} - A(s,f)\hat{j}(s,f)]}{G_{best(s,f),hom,K}} \quad (20)$$

选择稳定性

此处 π_j 为候选 j 在重复外层审计单元中被选中的比例，与 CAHit@q 定义中的排序截断 q 不同。公式 (21) 定义标准化选择熵。

$$H_{sel} = -\sum_j \pi_j \ln(\pi_j) \quad ; \quad H_{sel,norm} = \frac{H_{sel}}{\ln(K)} \quad (21)$$

数值稳定常数取 $\varepsilon_{num} = 10^{-12}$ 。Ledoit–Wolf 收缩采用缩放单位阵目标及 scikit-learn 的解析收缩系数估计；特征分解前将收缩协方差重新缩放为相关矩阵 $\mathbf{R}$ ，仅因浮点误差产生的微小负特征值裁剪为 0，并约定 $0 \log 0 = 0$ 。配对归一化增益与交叉拟合差距先在配对外层审计单元内计算，随后在每个种子内平均 3 个外层折，再以种子为区组进行端点内汇总；绝对分母不超过 ε_{num} 的单元记为缺失并单独报告。

2.16 统计推断

端点特异的 $K = 32$ 减 $K = 4$ 对比先在 10 个划分种子内平均 3 个外层折，再对种子区组进行 10 000 次重采样。分类采用种子化分层骨架组折，回归在全部 10 次当前运行中采用种子化骨架组平衡折。历史无种子的回归 GroupKFold 仅用于划分转换审计，不混入主

要估计量。重采样降低蒙特卡洛误差，但不会增加 10 个种子所提供的信息量；95%区间为描述性划分种子敏感性区间，不是针对未见分子端点的总体置信区间。分类 ROC-AUC 与回归 RMSE 不合并，且未定义跨端点汇总 P 值或确认性多重性族。

“端点×候选池×K”单元并不独立。折效应在种子内平均，保留种子区组不确定性，方向计数仅作描述。组件与预算比较在端点、种子和折内配对。匹配规模结果是 220 个重叠已登记子集的分布摘要，分类与回归始终保留在不同数值轴。

2.17 实用等价与近等价候选集

分类任务回顾性锁定的 ROC-AUC 实用等价容差 τ 网格为 0.005、0.010 和 0.020，回归任务 RMSE 容差 τ 网格为 0.025、0.050 和 0.100。若所选候选与交叉拟合参考的差距不超过 τ ，则记为 τ 成功；同时报告交叉拟合近等价候选集大小。所有阈值分析均作为敏感性描述，不作为事后显著性检验。

2.18 PR-AUC 与少数类召回约束选择

在 5 个分类端点的冻结十种子嵌套划分上记录内层 ROC-AUC、PR-AUC 和操作点指标。每个内层折以其训练分区中频数较少的类别定义少数类，并枚举内层验证预测产生的全部不同 ROC 阈值。若至少一个阈值达到少数类召回 ≥ 0.80 ，则先最大化多数类召回；并列时依次选择更高的少数类召回、更高的平衡召回以及更接近 0.5 的阈值。若没有阈值达到 0.80，则在所有少数类召回有限的阈值上应用同一并列规则，并记录阈值不可行。候选最终阈值取 3 个内层折阈值的中位数，少数类标签取众数，不实施事后概率校准。候选选择先保留平均内层少数类召回 ≥ 0.80 的候选；若无候选合格，则保留完整资格前缀。随后最大化平均内层多数类召回，并依次以平均内层少数类召回、平均内层 PR-AUC 和预注册顺序解决并列。候选身份、聚合阈值和少数类标签在一次性外层折评价前冻结；报告阈值可行性、候选资格、外层目标满足、少数类与多数类召回、少数类漏检率、PR-AUC 和 ROC-AUC。

2.19 构造对照、顺序敏感性与恢复模拟

以重复候选、弱候选和互补候选构造依赖结构，并评估预注册前缀、随机顺序、随机子集及家族平衡组成。经验相关异方差模拟复用观测到的候选相关结构和噪声尺度，检验不同信号强度与候选数量下的排序恢复。五种子组成与可靠性结果始终标记为次要分析。

3 结果

3.1 有效多样性取决于矩阵构造

十种子主要外层有效多样性审计中， $K = 32$ 时九个端点的 Ledoit–Wolf 谱熵秩中位数分别为：原始效用 2.36、逐行中心化 19.25、固定参照相对效用 5.56、单元内秩 24.33。四种矩阵分别保留共同审计难度、去除共同水平位移、表达相对于预设参照的差异或仅保留顺序。 30×32 外层矩阵和 90×32 内层矩阵均不与五种子次要候选库组成分析合并（图 2；表 S6–S7）。

矩阵层级、估计器、留一种子、留一折及参照敏感性会改变数值幅度，但名义 K 与矩阵依赖有效秩仍是不同量。完整 IQR、范围、参与率秩、收缩系数、相关性摘要及内层矩阵结果见表 S6；留一单元与预设参照结果见表 S7。




图 2. 十种子矩阵依赖的候选多样性。A，比较原始、逐行中心化、固定参照相对和单元内秩外层效用矩阵的 Ledit-Wolf 谱熵秩；线为端点中位数，阴影为端点 IQR，灰色点线为名义 K。B，K = 32 时谱熵秩与参与率秩的一致性及其 45° 参考线。C，校正后的候选相关中位数。D，K = 32 固定参照相对端点估计；实线和虚线范围分别删除一个种子与一个外层折标签，青绿色实心点为完整十种子估计，空心菱形使用预设线性参照。每个外层矩阵含 30 个种子-折行；相应 90 行内层矩阵结果见表 S6-S7。

3.2 机会校正排序保真度随 K 变化

置换负对照位于机会校正后的零点附近。随着注入的验证—审计信号增强，CAHit@3 和标准化 MRR 增益提高，固定范围选择损失降低。这些结果表明，在所设定的置换和信号注入条件下，各指标呈现预期的零点与信号恢复行为，但不能据此推断真实生物化学机制（图 3A-B）。




图 3. 机会校正排序校准与 K 不变完整候选库效应。A，五种子次要分析的端点中位 CAHit@3、标准化 MRR 增益、端点 IQR 及 95% 随机排序包络。B，五种子次要正对照在 6 级注入验证—审计信号与 4 种候选数量下的恢复。C，十种子主要分析相对 K 不变 K = 32 交叉拟合参考的端点特异 K = 32 减 K = 4 完整候选库完成差距对比；分类 ROC-AUC 与回归 RMSE 使用独立坐标轴，负值表示 K = 32 差距更小，实心标记表示敏感性区间不含 0；数值与表 4 完全一致。D，五种子次要组成对照；K = 32 时各模式按设计等于完整候选库。

3.3 审计差距分解区分机会与兑现

分类任务中，K = 4 至 32 的平均观测审计最优增益由 0.0028 增至 0.0311 ROC-AUC，选择模型增益由 -0.0014 增至 0.0173。回归任务中，观测审计最优增益由 0.7619 增至 0.8078 RMSE 单位，选择模型增益由 0.7442 变为 0.7378；两类任务尺度不合并。

在两类任务中，观测机会的增加均快于实际兑现增益。审计最优增益接近零时兑现比例不稳定，因此仅作为机器可读次要结果（图 4A–B；表 S8）。




图 4. 选择差距分解与赢家乐观偏差。A 和 B 比较分类与回归的观测审计最佳收益和验证所选收益。C 展示同折有限集合机会差距与 K 依赖前缀内交叉拟合差距，属于次要分解或敏感性分析；主要 K 不变完整候选库完成差距估计见图 3C。为便于端点间可视化比较，C 使用端点内标准化效应，原始 ROC-AUC 与 RMSE 效应另行列示。D 显示候选真实效用相同时的有限审计赢家乐观偏差。

3.4 交叉拟合效应在终点间异质

相对于 K 不变的完整候选库参考，9 个端点中有 8 个端点的 K = 32 减 K = 4 完成差距对比为负，1 个端点为正；其中 7 个端点的描述性划分子敏感性区间不含 0。负值表示 K = 32 下相对于完整候选库参考的完成差距更小，正值表示 K = 4 下更小。图 3C、表 4 与本节由同一机器可读源表生成，不合并分类 ROC-AUC 与回归 RMSE 尺度。

表 4. K 不变完整候选库完成差距对比。

端点	K = 32 减 K = 4 对比 (95%敏感性区间)	解释
分类: ROC-AUC 完成差距对比		
BACE	-0.0195 (-0.0238, -0.0152)	K = 32 下完成差距更小; 区间不含 0
BBBP	-0.0263 (-0.0301, -0.0225)	K = 32 下完成差距更小; 区间不含 0
ClinTox	-0.0144 (-0.0241, -0.0031)	K = 32 下完成差距更小; 区间不含 0
HIA	-0.0022 (-0.0075, 0.0031)	区间包含 0
P-gp	-0.0222 (-0.0271, -0.0178)	K = 32 下完成差距更小; 区间不含 0
回归: RMSE 完成差距对比		
ESOL	0.0683 (0.0618, 0.0757)	K = 4 下完成差距更小; 区间不含 0

端点	K = 32 减 K = 4 对比 (95%敏感性 区间)	解释
FreeSolv	-0.0586 (-0.0912, -0.0263)	K = 32 下完成差距更小; 区间不含 0
Lipophilicity	-0.0947 (-0.0992, -0.0899)	K = 32 下完成差距更小; 区间不含 0
Caco2	-0.0049 (-0.0121, 0.0008)	区间包含 0

注：负值表示 K = 32 下相对于完整候选库参考的完成差距更小。区间为描述性划分种子敏感性区间。

留一种子参照可减弱同一单元最大值的循环性，但仍依赖相同公开端点和切分生成器。因此，正负结果属于端点限定的敏感性证据，而非外部验证。

3.5 有限审计最大值包含赢家乐观偏差

当候选两两相关为 0.9、有效审计量为 50 时，平均赢家乐观偏差由 K = 4 时的 0.046 个标准差增至 K = 32 时的 0.092 个标准差。在 K = 32 下，有效审计量为 25 时该值为 0.132，为 200 时为 0.047。较低候选相关产生更大的有限最大值，因为候选估计提供了更多独立噪声方向（图 4D）。

该模式是有限最大值的机械性质，而非经验偏差校正。真实候选的总体效用未必相等，终点特异依赖结构也可能偏离等相关。该模拟因而不估计经验终点的校正量；它说明，即使外层折未参与内层选择，观测有限审计最佳也不是总体性能上界。

3.6 等规模多视图收益具有终点依赖性

匹配规模多表征审计保留明显终点异质性：组成分布同时出现正、弱和负效应，更大 K 阶梯亦未消除差异。220 个 K = 3 子集共享候选成员，是同一候选池中的分布对比而非独立实验。

分类 ROC-AUC 增益与回归 RMSE 降低保持在不同轴上。完整子集身份、IQR、范围和阶梯结果见表 S9–S10（图 5）。




图 5. 等规模表征组成效应。A 展示全部 220 个登记 K=3 子集的终点特异性分布。B 汇总互斥的组成类别。C 展示 K=3、6、9 和 12 阶梯。D 使用终点 MAD 标准化效应，在一个连续森林图中展示全部终点；原始 ROC-AUC 收益和 RMSE 降低另行列示。

3.7 表征错误相关但具有部分互补性

四模型面板的预测相关和高错误 Jaccard 重叠均明显高于零，预测谱熵有效秩低于名义 4。候选错误既非独立也非完全相同。由于训练预算不等，这些结果仅说明固定配置下的错误结构，不能形成现代架构性能排序（图 6A）。

3.8 化学边界处可靠性下降

分类终点在低、中、高 Tanimoto 支持下的审计单元中位 ROC-AUC 分别为 0.842、0.914 和 0.925；回归中位 RMSE 分别为 1.337、1.097 和 0.767。新颖骨架以已见或相关骨架为 reference = 1 报告错误重叠、分歧和高错误富集相对变化（图 6B–C）。

ClinTox 面板将 ROC-AUC、PR-AUC、少数类召回、假阴性率、条件覆盖率和预测集大小分区显示，不把不同可靠性量合并为单一性能排名（图 6D）。




图 6. 化学支持边界下的预测可靠性。A 在对称四模型矩阵中合并预测相关与高错误 Jaccard 重叠，并使用两个独立色标。B 将分类 ROC-AUC、回归 RMSE、分类假阴性率以及分类和回归高错误富集整合为 Tanimoto 支持风险矩阵；单元格文字给出自然尺度中位数，颜色仅编码行内不利方向。C 在对数比值轴上报告新骨架相对于已见或相关骨架的错误重叠、模型分歧、高错误富集和假阴性富集变化。D 将四个固定配置模型的判别能力与少数类安全性指标分组展示；预测集大小仅为绘图从 1–2 尺度映射至 0–1。

3.9 结构分离下审计方向迁移但效应大小改变

在 ClinTox、BACE 和 ESOL 中，预设 CAHit@3 变化与交叉拟合差距方向从种子化骨架划分迁移至 Tanimoto 分量切分，但效应幅度及若干单独对比发生改变；有效秩顺序部分保留，绝对值仍依赖切分机制。

该三终点迁移分析不构成外部验证、时间切分鲁棒性或普适模型选择定律。完整区间、切分可行性、缺失单元和任务特异效应见表 S24–S26 及图 S19。

3.10 扩展的组成、稳定性与计算控制

在六个预设端点和三类候选池中，CAHit@3 从 $K = 4$ 到 $K = 32$ 在多数“端点×候选池”组合下降，而交叉拟合差距仍具有异质性。 $K = 32$ 时，多表征与现代增强相对同质候选池的验证选择增益在六个端点均为正；分类与回归原始效用不合并。完整计数见表 S33 和图 S16。

现代组件具有异质性：冻结语言模型表征、另行锁定的一轮 D-MPNN 与完整现代候选池在不同端点和候选规模下并未产生一致贡献。组件层面的配对结果见表 S33 和图 S17。

等预算截断与选择稳定性分析表明，实际收益取决于锁定的候选前缀顺序及有限验证一致性。完整的等 K、等预算、选择频率与熵结果见表 S36 和图 S20–S21。

锚点与归一化选择对数值尺度的影响大于总体方向模式；多数预设方向在两种已评估切分机制间保持迁移，但效应幅度发生改变。缺失单元与完整敏感性结果保留于表 S34–S35 和图 S18–S19。




图 7. 扩展候选池组成干预。A, K = 32 时采用配对同质候选池审计最佳归一化, 并展示六个预设端点的选择值与有限审计最佳机会。B, 分别在分类和回归任务区段展示 K = 4、8、16 和 32 下的验证选择增益与交叉拟合差距, 候选池图例仅显示一次。C, 展示各端点、候选池和 K 组合的 CAHit@3, 负值完整保留; 主图最右侧 Entropy 列报告 K = 32 的标准化候选选择熵。H 表示同质 Morgan, MV 表示经典多表征, M 表示现代增强。D, 比较等 K 圆点与等下游预算菱形条件下的标准化选择增益和下游拟合/预测时间; 标记面积表示 K, 并展示经验 Pareto 前沿。该组成干预为五种子次要分析, 先在种子内平均 3 个外层折; 时间不含模型获取、编码器预训练和缓存嵌入提取。

3.11 实用等价与指标依赖选择

固定 K = 32 交叉拟合参考身份可避免随 K 改变比较对象。K = 32 时, 分类在 ROC-AUC 容差 0.005、0.010 和 0.020 下的 τ 成功率分别为 62.7%、80.0% 和 86.0%; 回归在 RMSE 容差 0.025、0.050 和 0.100 下分别为 73.3%、79.2% 和 82.5%。任务匹配中间容差的合并描述性成功率为 79.6%, 平均交叉拟合近等价集合大小为 10.17, 所选候选属于该集合的比例为 85.9%, 验证集与交叉拟合集合的平均 Jaccard 重叠为 0.490。这些均为回顾性锁定的报告容差, 不是临床或药理学阈值。

K = 32 时, PR-AUC 规则在 52.7%的单元中改变 ROC-AUC 所选候选, 并使外层 PR-AUC、ROC-AUC、少数类召回、多数类召回和少数类漏检率平均变化+0.0018、-0.0026、-0.0002、-0.0136 和+0.0002。少数类召回约束规则在 66.0%的单元中改变候选, 并使上述指标平均变化+0.0007、-0.0008、-0.0094、+0.0059 和+0.0094。K = 32 时 100.0%的单元存在内层合格候选, 但冻结规则仅在 62.0%的外层单元达到少数类召回 ≥ 0.80 ; 负的平均召回变化被完整保留, 不解释为约束可自动迁移(表 S38–S40)。

3.12 构造依赖对照与经验恢复

重复和弱候选扩大名义 K 而未相应增加有效机会, 互补候选的作用则依赖端点和信号强度。相关异方差模拟表明, 有限验证下的恢复率同时受候选相关性、噪声异质性和候选数量影响; 负结果完整保留在补充材料中。

3.13 次要背景与负结果

五种子候选库组成干预、计算暴露、化学支持与结构分离结果用于界定主要结论的适用范围, 不与十种子主要估计量合并。所有未观察到稳定改善或未达到约束目标的结果均在正文概述, 并在补充文件中提供机器可读细节。




图 8. 十种子主要审计中的实用等价与指标依赖选择。A 面板上下排列分类 ROC-AUC 和回归 RMSE 差距，使用独立纵轴并共享候选数 K 横轴；圆点/实线、方块/虚线和三角/点线分别表示 K 不变、 K 依赖和同折估计量，使灰度打印时仍可区分。B 展示回顾性锁定中间实用等价容差 τ 下各 K 的交叉拟合 τ 成功率。C 在单一纵轴上展示交叉拟合近等价集合的平均大小，B 中的分类/回归图例同时适用于 C。D 明确标示五个分类端点的 PR-AUC 候选切换、召回规则候选切换、 Δ PR-AUC 和 Δ 少数类召回；少数类召回负结果完整保留。A-D 按 2×2 四联图排列。

4 讨论

4.1 名义 K 不能定义候选多样性

候选数量、家族数量、表征数量、计算暴露和有效多样性描述模型搜索的不同维度。

名义 K 记录可选择候选数，家族与表征数描述登记组成，计算暴露记录拟合机会；这些量均不能直接证明候选在审计单元上的行为独立性。

登记前缀随 K 机械增加候选与计算暴露，但候选共享表征和相近学习器。有效多样性仅概括既定终点与划分中的效用模式，因此报告时应将搜索规模、登记组成、计算暴露和矩阵依赖有效多样性分开。

4.2 矩阵构造改变有效秩解释

原始效用、逐行中心化效用、固定参照效用和单元内秩回答不同问题。原始矩阵保留共同审计难度；逐行中心化去除水平位移但引入行和约束；固定参照依赖预设参照；秩矩阵保留顺序却丢失效用间距。

主要十种子分析中，每个终点包含 30 个外层审计单元。由于最大候选数 $K = 32$ 仍略高于审计单元数，未经收缩的经验候选相关矩阵可能秩亏。Ledoit–Wolf 收缩能够稳定协方差方向，但不会创造新的独立信息。谱熵秩与参与率秩对特征谱赋权不同，因此二者均与留一种子、留一折和预设参照敏感性结果共同报告。

4.3 机会校正的排序不一致伴随选择差距

原始获胜者恢复会随 K 机械变难，因此解释依赖机会校正和分级排序量。CAHit@3 评价外层最佳是否进入验证短名单，标准化 MRR 相对随机期望评价其位置，NDCG、Spearman、Kendall 和秩百分位刻画更广泛的重排。

置换负对照使两个机会校正指标回到随机排序零点附近，所有 K 下的观测 CAHit@3 终点中位数均高于相应置换包络。在分级正对照中，随着注入的验证—审计信号增强，CAHit@3 和标准化 MRR 单调提高，固定范围选择损失单调降低，并在完全信号条件下降至零。这些结果表明，各指标在所设定的模拟条件下具有预期的零点与信号恢复行为；但该诊断不能证明真实终点中单一排序指标与选择损失之间存在因果关系。

4.4 交叉拟合将主要比较与同折机会界分离

同折最大值使用被评价外层分数定义参照，可能夸大选择器可利用的机会。留一 seed 交叉拟合将参照选择与留出 seed 评价分离，在多数终点削弱同折效应，同时保留正负结果。因此，交叉拟合差距作为主要回顾性比较，同折差距只解释为有限候选机会界。

交叉拟合没有消除有限最大值乐观性、登记条件化或公开终点复用。已知真值模拟只说明最大化带噪候选估计的机械性质，不用于偏差校正。该参照仍是敏感性证据而非外部验证；同时报告交叉拟合与同折机会界，可揭示结论对被评价单元最大值的依赖。

4.5 等规模分析修正多视图解释

完整枚举 220 个重叠等规模子集，在固定候选数下改变表征和学习器组成。这些子集描绘同一登记表中的敏感性，并非独立实验；互斥组成类别避免把平衡、拼接、表征和学习器标签解释为独立因素。

终点分布保留 BACE 负中位效应及其他弱效应，且不合并 ROC-AUC 收益和 RMSE 降低。更大 K 阶梯仍交织表征广度、学习器相互作用和额外选择机会，因此只支持依赖终点的组成效应。

4.6 可靠性仍取决于化学支持

Tanimoto 支持、新颖骨架和活性悬崖表明选择结果依赖化学邻域。错误重叠、分歧与支持分层性能是互补边界证据，不能由单一平均骨架分数替代。

ClinTox 说明判别、保形覆盖和筛选安全性必须分开。ROC-AUC 可能与罕见类别召回不足或较高假阴性风险并存；提高条件覆盖通常还会扩大预测集。这些分析限定模型选择审计，不证明部署就绪。

4.7 切分迁移降低但未消除设计依赖

在禁止跨折 Tanimoto ≥ 0.70 的切分下，CAHit@3 变化和交叉拟合差距方向仍一致，削弱了主结果仅由普通骨架分配造成的解释；有效秩的较高秩相关也说明登记表的总体结构部分保留。

迁移并非数值不变。BACE 的 CAHit@3 变化在相似度聚类切分下接近零，标准化 MRR 并非一致降低，区间排零也随终点改变。因此应表述为三个代表终点的方向迁移，而非跨目标、时间切分、模型登记表或部署人群的普遍定律。

4.8 候选池组成、选择稳定性与受限计算

候选池组成改变选择器可利用的机会，有限验证决定机会能否兑现。候选扩张因而可能同时提高观测审计最优效用并增加选择压力。矩阵依赖的有效多样性补充了名义 K ，可描述候选效用在审计单元中的相对独立变化，但其本身不构成因果惩罚，也不能决定选择损失。

现代候选并非同质类别：冻结语言模型表征、另行锁定的一轮 D-MPNN 及完整现代候选池对各端点的影响不同。因此，现代增强可提高机会前沿，却不能保证内层选择器兑现全部增益。

等预算结果依赖预设前缀顺序，因为较昂贵的早期候选可能在后续互补候选进入前耗尽预算。锚点与归一化对效应尺度的影响大于方向。上述结论仅涉及受限下游拟合/预测暴露，不代表端到端架构效率，并限于已评估的端点、候选池和切分机制。

4.9 实用等价与指标匹配选择

实用等价集合可将注意力从不稳定的单一冠军转向在预先声明容差 τ 内可互换的候选，但 τ 具有任务尺度，必须在看到结果前锁定。PR-AUC 或少数类召回规则只改变选择目标，并不保证外层泛化约束被满足。

4.10 候选依赖与有限验证

构造对照和恢复模拟共同说明，新增候选的数量、独立信息量与验证可分辨性三个不同概念。报告名义 K 时应同时描述候选相关结构、顺序、可用性以及验证不确定性。

4.11 局限性

本研究是公开数据上的回顾性审计，不是前瞻性研究、独立外部验证或部署评价。

主要分析包含 10 个划分种子且每种子 3 个外层折，但不确定性信息主要来自 10 个种子区组；重采样不能增加这些区组所提供的独立信息。

K 不变完整候选库参考将参考选择与留出种子分离，但仍复用相同的公开端点、候选登记表和划分生成器。因此，该设计降低一种循环性，却不能替代独立队列或独立数据源验证。

实用等价容差 τ 是回顾性锁定的报告容差，不是临床、药理或工业最小重要差异。PR-AUC 和由训练数据定义的少数类召回规则改变了内层目标，但相应外层约束并未稳定迁移。

现代候选的覆盖范围有限。等预算分析只记录下游拟合/预测时间，不含模型获取、编码器预训练、缓存嵌入提取和完整端到端成本。Tanimoto 分量迁移仅覆盖 3 个端点和 1 种相似度规则。

端点、种子、折、候选及重叠子集相互依赖。重复、近重复、弱质和互补候选构造对照及经验恢复模拟支持机制解释，但不能证明有效多样性对选择差距具有单一因果效应。

5 结论

在已评估的端点、候选登记表和切分机制中，候选池扩张改变了可用模型机会、验证—审计排序一致性、选择稳定性和受限下游成本；这些变化依赖候选组成、选择指标、候选相关性、化学支持和具体端点。名义 K 与矩阵依赖效用模式多样性描述不同的搜索暴露，均不能单独概括交叉拟合选择差距。

因此，分子性质预测基准在报告最终预测性能的同时，还应报告锁定候选资格、登记表组成、候选数量阶梯、机会校正排序一致性、交叉拟合选择差距、描述性同折机会

界、选择稳定性、计算暴露和化学支持边界。现有审计不支持“候选越多必然越差”或“某类现代架构普遍更优/更劣”的结论。

补充信息

Additional file 1: 补充方法、结果与补充表说明。Additional file 2: 机器可读补充表 S1–S46。Additional file 3: 补充图 S1–S25。Additional file 4: 代码、环境、清单与复现说明。

声明

数据与材料可获得性

本研究所用公开数据源列于 Additional file 2 的 Table S1。处理后的审计表和复现材料包含在 Additional files 1–4 中。

当前可核验的公开 release 为: <https://github.com/zfr0857/FZYC-Mol/releases/tag/paper-release-2026-07-r9>。

固定 commit 为: 9635a902fa3cc7bb7b71a234c1b2bbbe415193f0。

Additional file 4 包含该公开基础及发布后新增的 paper43 十种子完成层。由于该完成层尚未出现在可核验的公开 r10 tag 中，仓库同步仍是投稿阻断项。

本轮审阅时没有可用的独立归档 DOI。

竞争性利益

[未提供—CONFLICT HOLD; 未据此推断不存在竞争性利益。]

基金资助

[未提供—CONFLICT HOLD; 未据此推断‘不适用’。]

作者贡献

[未提供—CONFLICT HOLD; 需由作者按真实姓名首字母和 CRediT 角色填写。]

致谢

[未提供—CONFLICT HOLD; 未据此推断‘不适用’。]

参考文献

1. Wu Z, Ramsundar B, Feinberg EN, et al. MoleculeNet: a benchmark for molecular machine learning. Chem Sci. 2018;9:513–530. doi:10.1039/C7SC02664A.

2. Huang K, Fu T, Gao W, et al. Therapeutics Data Commons: machine learning datasets and tasks for drug discovery and development. *NeurIPS Datasets and Benchmarks Track*. 2021. arXiv:2102.09548.
3. Cawley GC, Talbot NLC. On over-fitting in model selection and subsequent selection bias in performance evaluation. *J Mach Learn Res*. 2010;11:2079–2107.
4. Varma S, Simon R. Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics*. 2006;7:91. doi:10.1186/1471-2105-7-91.
5. Zhao D, Zhu Y, Wu Z, et al. Revisiting ADMET prediction reliability under real-world challenges in the foundation model era. *J Cheminform*. 2026;18:95. doi:10.1186/s13321-026-01217-2.
6. Zhang L, Zeng Y, Qi Y, et al. DCPM-ADMET: fusion of dual-component pre-trained model and molecular fingerprints to enhance drug ADMET properties prediction. *J Cheminform*. 2026. doi:10.1186/s13321-026-01244-z.
7. Jang Y, Lee J, Jeong K, Kim J. Multimodal graph fusion with statistically guided parsimonious descriptor selection for molecular property prediction. *J Cheminform*. 2026;18:18. doi:10.1186/s13321-025-01140-y.
8. Zhang Y, Liu W, Zhao H, et al. MolGramTreeNet: a multimodal molecular property prediction model via grammar tree-constrained molecular representation. *iScience*. 2026;29:114928. doi:10.1016/j.isci.2026.114928.
9. Wen X, Liu H, Long W, Wei S, Zhu R. Consistent semantic representation learning for out-of-distribution molecular property prediction. *Brief Bioinform*. 2025;26:bbaf147. doi:10.1093/bib/bbaf147.
10. Yin T, Gao P, Panapitiya G, Saldanha EG. Out-of-distribution evaluation of active learning pipelines for molecular property prediction. *RSC Adv*. 2026;16:5281–5295. doi:10.1039/D5RA08055J.
11. Uchibori Y, Kaneko H. Generation of molecules near the applicability domain boundaries of property prediction models. *J Chem Inf Model*. 2026;66:6866–6879. doi:10.1021/acs.jcim.5c03220.
12. Kim JY, Vlachos DG. Distance-aware molecular property prediction in nonlinear structure–property space. *J Chem Inf Model*. 2025;65:6744–6756. doi:10.1021/acs.jcim.5c01037.
13. Tang H, Yue T, Li Y. Assessing uncertainty in machine learning for polymer property prediction: a benchmark study. *J Chem Inf Model*. 2025;65:6585–6598. doi:10.1021/acs.jcim.5c00550.
14. Fralish Z, Reker D. Pairwise learning for molecular property prediction and optimization. *Front Drug Discov*. 2026;6:1859068. doi:10.3389/fddsv.2026.1859068.
15. Landrum G. RDKit: open-source cheminformatics software. Version 2026.3.1. <https://www.rdkit.org/>. Accessed 12 July 2026.
16. Rogers D, Hahn M. Extended-connectivity fingerprints. *J Chem Inf Model*. 2010;50:742–754. doi:10.1021/ci100050t.
17. Breiman L. Random forests. *Mach Learn*. 2001;45:5–32. doi:10.1023/A:1010933404324.
18. Ke G, Meng Q, Finley T, et al. LightGBM: a highly efficient gradient boosting decision tree. *Adv Neural Inf Process Syst*. 2017;30.
19. Chen T, Guestrin C. XGBoost: a scalable tree boosting system. *Proc ACM SIGKDD*. 2016:785–794. doi:10.1145/2939672.2939785.
20. Prokhorenkova L, Gusev G, Vorobev A, Dorogush AV, Gulin A. CatBoost: unbiased boosting with categorical features. *Adv Neural Inf Process Syst*. 2018;31:6638–6648.
21. Yang K, Swanson K, Jin W, et al. Analyzing learned molecular representations for property prediction. *J Chem Inf Model*. 2019;59:3370–3388. doi:10.1021/acs.jcim.9b00237.
22. Chithrananda S, Grand G, Ramsundar B. ChemBERTa: large-scale self-supervised pretraining for molecular property prediction. arXiv:2010.09885. 2020.
23. Ross J, Belgodere B, Chenthamarakshan V, et al. Large-scale chemical language representations capture molecular structure and properties. *Nat Mach Intell*. 2022;4:1256–1264. doi:10.1038/s42256-022-00580-7.
24. Erickson N, Mueller J, Shirkov A, et al. AutoGluon-Tabular: robust and accurate AutoML for structured data. arXiv:2003.06505. 2020.
25. Tropsha A. Best practices for QSAR model development, validation, and exploitation. *Mol Inform*. 2010;29:476–488. doi:10.1002/minf.201000061.
26. Vovk V, Gammernan A, Shafer G. *Algorithmic Learning in a Random World*. New York: Springer; 2005. doi:10.1007/b106715.
27. Shafer G, Vovk V. A tutorial on conformal prediction. *J Mach Learn Res*. 2008;9:371–421.
28. Guo C, Pleiss G, Sun Y, Weinberger KQ. On calibration of modern neural networks. *Proc ICML*. 2017;70:1321–1330.

29. van Tilborg D, Alenicheva A, Grisoni F. Exposing the limitations of molecular machine learning with activity cliffs. *J Chem Inf Model*. 2022;62:5938–5951. doi:10.1021/acs.jcim.2c01073.
30. Sheridan RP. Time-split cross-validation as a method for estimating the goodness of prospective prediction. *J Chem Inf Model*. 2013;53:783–790. doi:10.1021/ci400084k.
31. Demšar J. Statistical comparisons of classifiers over multiple data sets. *J Mach Learn Res*. 2006;7:1–30.
32. Hoyt CT, Zdrazil B, Guha R, et al. Improving reproducibility and reusability in the Journal of Cheminformatics. *J Cheminform*. 2023;15:62. doi:10.1186/s13321-023-00730-y.
33. Parrondo-Pizarro R, Lanini J, Rodríguez-Pérez R. Uncertainty quantification in molecular machine learning for property predictions under data shifts. *J Chem Inf Model*. 2026;66:923–935. doi:10.1021/acs.jcim.5c02381.
34. Deng J, Yang Z, Wang H, Ojima I, Samaras D, Wang F. A systematic study of key elements underlying molecular property prediction. *Nat Commun*. 2023;14:6395. doi:10.1038/s41467-023-41948-6.
35. Li Z, Chen X, Wen H, et al. A systematic survey and benchmark of deep learning for molecular property prediction in the foundation model era. *arXiv:2604.16586*. 2026.
36. Romano Y, Patterson E, Candès EJ. Conformalized quantile regression. *Adv Neural Inf Process Syst*. 2019;32.
37. FZYC-Mol Authors. FZYC-Mol: candidate-pool expansion audit code and reproducibility package. Version paper-release-2026-07-r9 (commit 9635a902fa3cc7bb7b71a234c1b2bbbe415193f0). GitHub; 2026. Available from: <https://github.com/zfr0857/FZYC-Mol>. Accessed 22 July 2026.